

GLOBAL SOLUTION 2026.1

Economia Espacial



Grupo

Heitor Exposito de Sousa / rm566013

Marco Antônio Rodrigues Siqueira / rm569975

Nádia Nakamura Vieira / rm568906

Rafael Bassani / rm569930

Vinicius Xavier da Silva / rm572108

QUERO CONCORRER

Introdução

A economia espacial, impulsionada pela ampla disponibilidade de dados de satélite, oferece ferramentas poderosas para enfrentar desafios ambientais e agrícolas. No Brasil, país com vasta extensão territorial e biomas fundamentais para o equilíbrio climático global, o controle e a prevenção de queimadas são cruciais tanto para a sustentabilidade ecológica quanto para a segurança do agronegócio.

O principal problema atual não é a falta de dados, mas sim a **defasagem entre a detecção espacial e a ação em campo**. Modelos baseados exclusivamente em satélites operam com atrasos significativos (horas a dias), enquanto incêndios se alastram rapidamente, especialmente sob condições climáticas adversas.

Para solucionar essa lacuna, o projeto **Geo Fire** propõe um ecossistema híbrido que integra dados espaciais da NASA (FIRMS), previsão climática global (OpenMeteo), Machine Learning para predição de risco e sensores IoT (Edge Computing) para monitoramento local e emissão de alertas em tempo real. Esta abordagem multicamadas maximiza a eficiência na detecção e atua diretamente nos Objetivos de Desenvolvimento Sustentável da ONU, em especial o ODS 13 (Ação Contra a Mudança Global do Clima) e o ODS 15 (Vida Terrestre).

Arquitetura da Solução

O sistema Geo Fire opera em três camadas integradas:

1. **Camada Espacial (Dados e Clima):** Consome focos de calor ativos detectados por satélites via NASA FIRMS API. Esses dados são enriquecidos com o histórico climático detalhado da API do OpenMeteo (temperatura, umidade, vento, etc.).
2. **Camada Edge (Hardware e IoT):** Utiliza microcontroladores ESP32 acoplados a sensores instalados em campo ("Fazendas Fictícias"). Esta camada processa dados brutos localmente, aciona alertas sonoros/visuais emergenciais independentes de rede, e transmite o estado ambiental via HTTP para um servidor central.
3. **Camada de Análise (ML e Dashboard):** Processa os dados recebidos. Modelos de Machine Learning (RandomForest e K-Means) rodam nos bastidores para classificar o risco de incêndio. O usuário final interage através de um painel web interativo, onde acompanha o mapa regional, relatórios de risco e o status instantâneo dos sensores em solo.

A modelagem de dados que sustenta o ecossistema foi estruturada na Terceira Forma Normal (3FN), garantindo integridade e escalabilidade para o armazenamento do histórico climático, dos dados dos satélites e dos registros de telemetria.




Diagrama de Entidade e Relacionamento do banco de dados relacional (3FN).

Desenvolvimento e Stack Técnica

Planejamento e Metodologia

O desenvolvimento seguiu uma abordagem ágil com divisão clara de responsabilidades, assegurando entregas iterativas entre o início de junho e a finalização do projeto.

Papéis da equipe:

- **Heitor:** Arquitetura do projeto, estruturação do repositório, controle de versão (Git) e revisão de documentação.
- **Marco:** Desenvolvimento do modelo preditivo RandomForest e análise exploratória de dados (EDA).
- **Nadia:** Análise estatística com R e clusterização espacial (K-Means).
- **Rafael:** Engenharia de Hardware (C++/ESP32), simulação no Wokwi e desenvolvimento da API do Servidor IoT.
- **Vinicius:** Engenharia Frontend (Streamlit), integração do dashboard com o modelo preditivo e estruturação de dados.

Cronograma de entregas:

Etapa	Período	Status
Setup da arquitetura, repositório e ambientes de desenvolvimento	01 a 02 de Junho	✓
Coleta via APIs (NASA FIRMS + OpenMeteo) e Pipeline de Tratamento	03 a 04 de Junho	✓
Modelagem de Banco de Dados (MER 3FN)	05 de Junho	✓
Análise Exploratória (EDA) e Machine Learning (RandomForest)	06 a 07 de Junho	✓
Análise de Agrupamento Espacial (R e K-Means)	07 de Junho	✓

Etapa	Período	Status
Firmware C++, Simulação Wokwi e API IoT (FastAPI)	08 de Junho	✓
Integração do Dashboard Interativo (Streamlit) e Documentação Final	09 de Junho	✓

Coleta e Tratamento de Dados (Python)

A fundação do projeto reside no enriquecimento de dados espaciais com informações climáticas de alta resolução. Um script automatizado extrai focos da América do Sul e cruza as coordenadas com os registros do OpenMeteo para extrair *features* essenciais como `temp_mean`, `humidity` e `wind_speed`.

```
# Trecho de src/python/collect_weather.py
def collect_weather_for_dataset(df: pd.DataFrame, delay: float = 0.5) ->
pd.DataFrame:
    df = df.copy()
    df["_lat_round"] = df["latitude"].round(2)
    df["_lon_round"] = df["longitude"].round(2)
    unique_keys = df[["_lat_round", "_lon_round",
"acq_date"]].drop_duplicates()

    weather_cache = {}
    for i, (_, row) in enumerate(unique_keys.iterrows(), 1):
        lat, lon, date = row["_lat_round"], row["_lon_round"],
row["acq_date"]
        key = (lat, lon, date)
        if key not in weather_cache:
            weather = fetch_weather(lat, lon, date)
            weather_cache[key] = weather if weather is not None else {p: None
for p in DAILY_PARAMS + HOURLY_PARAMS}
            time.sleep(delay)
```

Análise de Dados Exploratória (EDA)

Durante a fase exploratória, processamos mais de 2.000 focos de calor referentes às capturas do dia 08 de Junho de 2026, conforme extração direta da API do FIRMS.

A análise guiou a seleção das *features* climáticas para treinar o modelo preditivo, evitando a utilização de variáveis que resultariam em circularidade lógica (como o próprio FRP).

Notavelmente, observamos uma forte correlação inversa entre a umidade relativa do ar e o índice de poder radiativo do fogo (FRP), conforme evidenciado no gráfico abaixo:




Gráfico de dispersão gerado na EDA evidenciando que os focos de incêndio mais severos (FRP alto) ocorrem majoritariamente em faixas de baixa umidade do ar.

Machine Learning — Modelo RandomForest (Python)

Para prever o nível de perigo, implementamos um classificador multivariado utilizando o algoritmo RandomForest. O modelo recebe as condições meteorológicas (`temp_max`, `temp_min`, `humidity`, `wind_speed`, `precipitation`, `soil_moisture`) e prevê uma classe de risco: "Baixo", "Médio" ou "Alto".

O modelo atingiu **84.10% de acurácia global**. Uma descoberta importante (via *Feature Importance*) é que, logo após a temperatura, a velocidade máxima do vento é a variável climática que mais determina o agravamento do risco de queimadas.

```
# Trecho de treinamento do modelo
from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import train_test_split

X = df[['temp_max', 'temp_min', 'humidity', 'wind_speed', 'precipitation',
        'soil_moisture']]
y = df['risk_label']

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3,
                                                    random_state=42)

model = RandomForestClassifier(n_estimators=200, max_depth=10,
                              random_state=42)
model.fit(X_train, y_train)
```

Clusterização Espacial — K-Means (R)

Empregou-se a linguagem R para a aplicação do algoritmo K-Means, agrupando (clusterizando) os dados históricos de queimadas. O propósito foi identificar zonas endêmicas que compartilham características geográficas e de severidade climática/fogo.

A análise revelou três agrupamentos bem delineados:

- **Cluster 1 (Zonas Críticas):** Agrupa os incêndios com a maior severidade média (FRP ~14.07 MW), que estão fortemente associados à menor umidade relativa (55.72%) e maiores temperaturas e ventos. Representa o núcleo das queimadas mais agressivas e perigosas da amostra.
- **Cluster 2 (Risco Moderado):** Concentra ocorrências em zonas com a menor temperatura média (~19°C) e índices pluviométricos escassos. Indica focos sob condições climáticas ligeiramente mais controladas, mas espalhados por uma vasta área.
- **Cluster 3 (Risco Baixo/Manejo):** Locais caracterizados por alta umidade (~85%) e precipitação elevada (4.57 mm médios). Os focos aqui apresentam o menor FRP


médio (~7.78 MW), muito possivelmente englobando pequenas queimas para manejo agrícola que não se alastraram.

```
# Trecho de src/r/kmeans_risco.R
library(ggplot2)
library(cluster)

cols_cluster <- c("latitude", "longitude", "frp", "temp_mean", "humidity",
"precipitation", "wind_speed")
df_cluster <- na.omit(df[, cols_cluster])

df_scaled <- scale(df_cluster)
set.seed(123)
km <- kmeans(df_scaled, centers = 3, nstart = 25)

df_cluster$cluster <- as.factor(km$cluster)
```




Resultado da clusterização em 3 agrupamentos distintos.

Hardware e Edge Computing — ESP32 (C++ / Wokwi)

Para atuar diretamente no campo (IoT), um firmware em C++ foi desenvolvido para um ESP32. O circuito consolida leituras de temperatura/umidade ambiente (DHT22), além de detectores de gases inflamáveis/fumaça (MQ-2), precipitação e umidade do solo.

Decisão de Projeto: Devido a limitações de componentes nativos disponíveis no simulador Wokwi, optamos arquiteturalmente por utilizar potenciômetros para emular a resistência analógica dos sensores de precipitação (chuva) e de umidade do solo, mapeando as leituras puras do ADC (0-4095) para percentuais (0-100%).

O dispositivo processa lógicas de alerta imediatamente, soando um alarme caso limiares críticos sejam rompidos (ex: fumaça intensa ou temperatura maior que 50°C), mesmo se houver falha na rede. Quando o WiFi está disponível, o dispositivo sincroniza seu relógio usando o protocolo NTP e emite pacotes JSON.



Circuito do protótipo IoT (simulação via Wokwi).

```
// Trecho de esp32/src/firmware.ino
float temp = readDHTTemp();
int smokeRaw = analogRead(PIN_MQ2);

// Alerta local: acionamento imediato
bool alert = (smokeRaw > SMOKE_THRESHOLD) || (temp > TEMP_THRESHOLD);
digitalWrite(PIN_LED, alert ? HIGH : LOW);
digitalWrite(PIN_BUZZER, alert ? HIGH : LOW);

// Formatação do JSON com Timestamp local NTP
String jsonPayload = "{\"timestamp\":\"" + String(ts) + "\",";
jsonPayload += "\"temperature\":\"" + String(temp, 1) + "\",";
jsonPayload += "\"humidity\":\"" + String(humidity, 1) + "\",";
jsonPayload += "\"precipitation\":\"" + String(rainPct) + "\",";
jsonPayload += "\"soil_moisture\":\"" + String(soilPct) + "\"}";
```


IoT Server & API (FastAPI)

Para receber o volume de telemetria dos dispositivos no campo, um backend simples em Python (FastAPI) atua como barramento, recebendo os POSTs HTTP dos ESP32 e registrando os payloads para consumo do painel de monitoramento.


Dashboard Interativo (Streamlit)

O painel web condensa todas as tecnologias empregadas, oferecendo duas visões principais:

1. **Visão Espacial/Regional:** Um mapa interativo detalha as detecções reais de satélite. O usuário pode simular o risco futuro para qualquer coordenada através da integração do modelo preditivo com as previsões da API do *OpenMeteo*.
2. **Visão IoT/Micro:** Acompanhamento dos sensores da "Fazenda Fictícia" em tempo real, conectando diretamente os dados do campo com as previsões do *RandomForest*.



Visão Geral do sistema com os dados de focos de incêndio mapeados espacialmente.



Aba de previsão para a Fazenda Fictícia, que funde a leitura instantânea dos sensores IoT à inferência de IA.

Integração Multidisciplinar

O Geo Fire reflete a convergência das diretrizes de várias disciplinas curriculares de IA em uma única solução sólida:

Disciplina	Papel e Componente Entregue	Tecnologia Empregada
Computational Thinking with Python	Extração de APIs, engenharia de dados (Pandas) e o desenvolvimento do Dashboard interativo completo.	Python, Pandas, Streamlit.
IA Computer Systems and Sensors	Montagem da eletrônica (Edge), firmware do microcontrolador e aquisição de dados físicos dos sensores.	ESP32, C++, Wokwi, DHT22.
Machine Learning and Modelling	Desenvolvimento do modelo preditivo supervisionado para classificação das categorias de risco de incêndio.	Python, Scikit-learn, RandomForest.
Cognitive Data Science	Concepção, modelagem conceitual e estruturação do banco de dados relacional.	MER (Modelo Entidade-Relacionamento) e 3FN.
Statistical Computing with R	Algoritmos de aprendizado não supervisionado para encontrar similaridades geográficas e endêmicas (zonas de urgência).	R, ggplot2, Algoritmo K-Means.
Formação Social e Sustentabilidade / IA Challenges	Foco na sustentabilidade agrícola e adoção de inovações tecnológicas baseadas na Economia Espacial para fins ESG.	APIs NASA FIRMS, ODS 13 e 15.

Resultados e Limitações

Resultados Consolidados

- A combinação de Inteligência Artificial com o histórico meteorológico gerou um modelo classificador estável (Acurácia de ~84%), comprovando que mudanças de clima locais precedem a severidade radiativa mapeada no espaço.
- O K-Means em R provou ser incrivelmente capaz de segmentar o que são possíveis queimas de manejo (baixa temperatura, alta umidade) de incêndios florestais fora de controle (Cluster 1).
- A integração das três camadas funcionou fluidamente: de C++ (no ESP32) para Python (Servidor e ML), unindo o melhor da instrumentação local e da análise preditiva global.

Limitações Identificadas (Trabalhos Futuros)

Embora muito funcional como Prova de Conceito (PoC), mapeamos deficiências técnicas importantes na busca por uma solução *production-ready*:

1. **Incompatibilidade de Grandezas (IoT vs Clima):** O modelo RandomForest foi treinado usando a umidade do solo histórica em m^3/m^3 (OpenMeteo), mas o sensor analógico simulado da camada Edge reporta variações percentuais brutas (0-100%). Há um claro desvio na predição no cenário da "Fazenda", algo que será solucionado ajustando a curva de calibração do sensor e adequando as *features*.
2. **Ausência de Sensor de Vento (Edge):** O modelo identificou o vento como o segundo maior responsável pelo risco, porém, o protótipo ESP32 atual não dispõe de um anemômetro. Devido a isso, a previsão em tempo real do dashboard assume ausência de vento, subestimando as condições críticas momentâneas.
3. **Desbalanceamento de Classes (ML):** Os registros de energia radiativa altíssima (FRP > 50 MW) configuram menos de 4% de todo o dataset da América do Sul no dia extraído, desbalanceando o treinamento para a classe "Risco Alto". Técnicas estatísticas de *Oversampling* deverão ser introduzidas na refatoração do pipeline.

Conclusões

O projeto **Geo Fire** ilustra, de ponta a ponta, como as informações muitas vezes restritas a laboratórios espaciais podem ser democratizadas através da programação, em conjunto com ferramentas baratas de hardware de solo.

Do ponto de vista mercadológico e governamental, o monitoramento preventivo que agrega Machine Learning evita o custo astronômico da resposta passiva aos incêndios e reforça o valor de se aplicar os conceitos de sustentabilidade baseada em dados como uma verdadeira estratégia competitiva e ética (ESG).

Links Oficiais

- **Vídeo Demo:** <https://youtu.be/JCbrSeO46HI>
- **Repositório GitHub:** <https://github.com/AI-FIAP-2026/geo-fire>
- **Fontes (APIs):** [NASA FIRMS API](#) e [OpenMeteo](#).